

Αυτόματη Μουσική Μεταγραφή από Ηχογραφήσεις Πιάνου σε Αρχεία MIDI

Δάλλας Γεώργιος 217, Διαμαντίδης Γεώργιος 216,
Εμμανουηλίδης Αθανάσιος 211

1 Εισαγωγή

Η αυτόματη μουσική μεταγραφή αποτελεί ένα σημαντικό πρόβλημα στον χώρο της επεξεργασίας ήχου αλλά και της μηχανικής μάθησης. Ο στόχος είναι η αυτόματη εξαγωγή μουσικής πληροφορίας από ένα ηχητικό σήμα/ηχογράφιση. Αυτή η διαδικασία είναι χρήσιμη σε εφαρμογές όπως στην αυτόματη δημιουργία παρτιτούρας από ηχογραφήσεις, στη μουσική ανάλυση και στην ανάκτηση μουσικής πληροφορίας.

Σε αυτή την εργασία εξετάζεται το πρόβλημα της αυτόματης μουσικής μεταγραφής από ηχογραφήσεις πιάνου σε αρχεία MIDI, δηλαδή σε μία συμβολική μορφή. Η είσοδος είναι μια ηχογράφιση ενός κομματιού κλασικής μουσικής, το οποίο μετατρέπεται σε μια χρονική-συχνотική αναπαράσταση (mel-spectrogram). Η έξοδος είναι μια αναπαράσταση της μουσικής πληροφορίας είτε με τη μορφή frame και onset piano-rolls, είτε με τη μορφή MIDI events.

Για την αντιμετώπιση του προβλήματος υλοποιούνται και συγκρίνονται διαφορετικά μοντέλα βαθιάς μάθησης. Συγκεκριμένα εξετάζεται ένα μοντέλο με CNN + LSTM, ένα που χρησιμοποιεί μόνο τον encoder από Transformer, ένα με CNN + Transformer encoder και τέλος, ένα Transformer Encoder-Decoder.

Σκοπός της εργασίας είναι η αξιολόγηση των μοντέλων ως προς την ικανότητά τους να μεταγράφουν τις ηχογραφήσεις πιάνου, αλλά και η σύγκριση μεταξύ των μοντέλων και των διαφορετικών τρόπων υλοποίησης.

2 Ορισμός προβλήματος

Στο πρόβλημα της αυτόματης μουσικής μεταγραφής από ηχογραφήσεις σε MIDI, ο σκοπός του μοντέλου μηχανικής μάθησης είναι από μία είσοδο (ηχογράφιση) να μπορεί να παράξει με ακρίβεια τη δομημένη αναπαράσταση

της μουσικής πληροφορίας (σε αυτή την περίπτωση το MIDI). Υπάρχουν δύο τρόποι με τους οποίους μπορεί να γίνει αυτό.

Ο πρώτος τρόπος είναι να αντιμετωπιστεί το πρόβλημα ως μια frame-wise ταξινόμηση και να χωριστεί το μουσικό κομμάτι, αλλά και το αρχείο MIDI, σε χρονικά πλαίσια. Μέσα σε κάθε ένα χρονικό πλαίσιο καταγράφονται ποιες νότες του πιάνου είναι ενεργές εκείνη τη στιγμή. Αυτό μπορεί να θεωρηθεί ως το piano roll που περιέχει τις ενεργές νότες (frame piano roll). Συγκεκριμένα, σε αυτή την εργασία, εκτός από το frame piano roll, χρησιμοποιείται και η έννοια του onset, δηλαδή σε ποιο χρονικό πλαίσιο (frame) ξεκινάει η νότα. Επίσης, και αυτό μπορεί να θεωρηθεί ως ένα piano roll. Χρησιμοποιείται συνδυάζοντας το με το frame piano roll γιατί είναι αρκετά σημαντικό η νότα να ξεκινάει τη σωστή χρονική στιγμή. Συνολικά χρησιμοποιούνται το frame piano roll και το target piano roll ως target. Το κάθε διάλυμα του piano roll αναπαριστά τα 88 πλήκτρα του πιάνου.

Ο δεύτερος τρόπος είναι πάλι να χωριστεί το μουσικό κομμάτι και το αρχείο MIDI σε χρονικά πλαίσια, αλλά αντί να καταγράφονται ποιες νότες του πιάνου είναι ενεργές εκείνη τη χρονική στιγμή, να χρησιμοποιηθούν τα MIDI events εκείνου του πλαισίου κατευθείαν για την εκπαίδευση. Αυτή τη φορά, αντί να παραχθούν piano rolls για κάθε χρονικό πλαίσιο, παράγεται κατευθείαν η πληροφορία MIDI.

3 Σύνολο δεδομένων

Στην εργασία χρησιμοποιείται το MAESTRO dataset ως σύνολο δεδομένων για το πρόβλημα του Automatic Music Transcription. Το σύνολο δεδομένων MAESTRO, του οποίου το όνομα προέρχεται από το MIDI and Audio Edited for Synchronous TRacks and Organization, αποτελείται από ηχογραφήσεις πιάνου μαζί με τα αντίστοιχα MIDI. Οι ηχογραφήσεις προέρχονται από βιρτουόζικους διαγωνισμούς πιάνου, όπου τα κομμάτια έχουν εκτελεστεί σε Yamaha Disklaviers. Τα Disklaviers επιτρέπουν την καταγραφή των MIDI αρχείων με μεγάλη πιστότητα στην εκτέλεση και την ηχογράφηση, καθώς και υψηλή ακρίβεια ευθυγράμμισης, 3 ms.

Το σύνολο δεδομένων αποτελείται από περίπου 200 ώρες ζευγαριών ηχογραφήσεων και MIDI. Τα αρχεία MIDI, εκτός από την καταγραφή των νοτών, περιέχουν και το velocity, δηλαδή το πόσο δυνατά και γρήγορα έχει πατηθεί το πλήκτρο, καθώς και τη χρήση των τριών πεταλιών του πιάνου. Επιπλέον, τα αρχεία ήχου βρίσκονται σε μορφή υψηλής ποιότητας (CD quality ή υψηλότερη). Συγκεκριμένα, σε αυτή την εργασία δεν χρησιμοποιείται όλο το MAESTRO dataset, αλλά ένα υποσύνολό του. Η χρήση του υποσυνόλου γίνεται λόγω των περιορισμένων υπολογιστικών πόρων και του χρόνου εκπαίδευσης.

Συγκεκριμένα, τα αρχεία που επιλέγονται είναι από τους διαγωνισμούς που έγιναν το 2011, το 2013 και το 2014. Τα ίδια δεδομένα χρησιμοποιούνται για όλα τα μοντέλα, ώστε η σύγκριση των αποτελεσμάτων να είναι δίκαιη.

4 Προεπεξεργασία δεδομένων

Πριν από την εκπαίδευση των μοντέλων πραγματοποιήθηκε προεπεξεργασία των αρχικών δεδομένων με στόχο την κατάλληλη μορφή εισόδου και εξόδου για τα μοντέλα.

Αρχικά, τα αρχεία ήχου μετατράπηκαν σε κοινό ρυθμό δειγματοληψίας 16 kHz, ώστε όλα τα δείγματα να έχουν κοινή χρονική ανάλυση. Από τα αρχεία MIDI εξήχθησαν τα MIDI events για το τονικό ύψος (pitch), τη χρονική στιγμή έναρξης (onset) και τη χρονική στιγμή λήξης (offset) κάθε νότας. Στη συνέχεια, κάθε μουσικό κομμάτι χωρίστηκε σε μικρότερα αποσπάσματα των 20 δευτερολέπτων. Ο χωρισμός έγινε για την υπολογιστική ευκολία κατά την εκπαίδευση των μοντέλων. Κατά τον χωρισμό κρατήθηκαν μόνο οι νότες που βρίσκονται πλήρως μέσα στο απόσπασμα, ενώ οι χρονικές στιγμές έναρξης και λήξης τους μετατοπίστηκαν ώστε να είναι σχετικές με την αρχή του κάθε αποσπάσματος.

Στη συνέχεια, για κάθε απόσπασμα ήχου υπολογίστηκε το mel-spectrogram, το οποίο χρησιμοποιείται ως είσοδος των μοντέλων. Υπολογίστηκε με 229 mel bands και hop length 512 και μετατράπηκε σε λογαριθμική κλίμακα. Οπότε η ανάλυση του κάθε frame είναι 32 ms.

Τα MIDI γεγονότα κάθε αποσπάσματος ευθυγραμμίζονται χρονικά με τα frames του mel-spectrogram. Ανάλογα με τη μορφή εξόδου που απαιτεί κάθε μοντέλο, η πληροφορία των αρχείων χρησιμοποιήθηκε με διαφορετικό τρόπο. Για το πρόβλημα της frame-wise ταξινόμησης, δημιουργήθηκαν δύο piano roll αναπαραστάσεις, το frame piano roll, το οποίο περιέχει ποιες νότες είναι ενεργές σε κάθε χρονικό πλαίσιο, και το onset piano roll, το οποίο καταγράφει σε ποιο χρονικό πλαίσιο ξεκινάει η κάθε νότα. Για το μοντέλο Transformer Encoder-Decoder, τα MIDI γεγονότα διατηρήθηκαν σε μορφή ακολουθίας γεγονότων.

5 Μεθοδολογία

5.1 CNN + LSTM

Το μοντέλο CNN + LSTM βασίζεται στην αρχιτεκτονική Onsets and Frames, όπως παρουσιάστηκε από τους Hawthorne et al. (2018). Η αρχιτεκτονική αυτή

αντιμετωπίζει το πρόβλημα του Automatic Music Transcription με διπλό στόχο: την ταυτόχρονη πρόβλεψη των onset (έναρξη νότας) και frame (διάρκεια νότας) στο piano roll, αξιοποιώντας τη συνεργασία μεταξύ των δύο αναπαραστάσεων.

Η αρχιτεκτονική αποτελείται από τρία επιμέρους δίκτυα: τον Onset Detector, τον Frame Detector και τον Velocity Detector. Κοινό component και για τα τρία αποτελεί ένα συνελκτικό δίκτυο (ConvStack), το οποίο επεξεργάζεται το mel-spectrogram εισόδου. Η είσοδος του ConvStack είναι ένα mel-spectrogram σχήματος $(B, 1, T, n_mels)$, όπου B είναι το batch size, T ο αριθμός χρονικών πλαισίων και $n_mels=229$ ο αριθμός των mel bins.

Το δίκτυο αποτελείται από τέσσερα συνελκτικά layers με πυρήνες 3×3 οργανωμένα σε δύο μπλοκ:

- **Πρώτο μπλοκ:** $\text{Conv}(1 \rightarrow 32) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}(32 \rightarrow 32) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(1 \times 2) \rightarrow \text{Dropout}(0.25)$
- **Δεύτερο μπλοκ:** $\text{Conv}(32 \rightarrow 64) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}(64 \rightarrow 64) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(1 \times 2) \rightarrow \text{Dropout}(0.25)$

Κάθε MaxPool εφαρμόζεται μόνο στη διάσταση των συχνοτήτων (1×2), διατηρώντας αναλλοίωτη τη χρονική διάσταση. Μετά τα δύο μπλοκ, η συχνοτική διάσταση έχει μειωθεί στα $1/4$, οπότε ισχύει $\text{freq_out} = n_mels/4 = 57$. Η έξοδος αναδιατάσσεται σε σχήμα $(B, T, 64 \cdot \text{freq_out}) = (B, T, 3648)$, ώστε να μπορεί να τροφοδοτηθεί σε recurrent ή πλήρως συνδεδεμένα στρώματα.

Ο Onset Detector έχει ως στόχο να εντοπίσει τα χρονικά πλαίσια στα οποία ξεκινά μια νότα. Η αρχιτεκτονική του ακολουθεί τη σειρά: $\text{ConvStack} \rightarrow \text{BiLSTM}(128) \rightarrow \text{FullyCon}(88) \rightarrow \text{Sigmoid}$.

Το ConvStack εξάγει ακουστικές αναπαραστάσεις σχήματος $(B, T, 3648)$. Στη συνέχεια, ένα διπλής κατεύθυνσης LSTM (Bidirectional LSTM) με 128 units ανά κατεύθυνση επεξεργάζεται την ακολουθία, παράγοντας έξοδο σχήματος $(B, T, 256)$. Τέλος, ένα πλήρως συνδεδεμένο layer αντιστοιχίζει κάθε χρονικό πλαίσιο σε 88 πιθανότητες onset, μία για κάθε πλήκτρο του πιάνου, οι οποίες ενεργοποιούνται μέσω Sigmoid.

Ο Frame Detector προβλέπει αν κάθε πλήκτρο είναι ενεργό (δηλαδή η νότα παίζεται) σε κάθε χρονικό πλαίσιο. Η αρχιτεκτονική του ακολουθεί τη σειρά: $\text{ConvStack} \rightarrow \text{FullyCon}(88) \rightarrow \text{Σύνδεση με onset} \rightarrow \text{BiLSTM}(128) \rightarrow \text{FullyCon}(88) \rightarrow \text{Sigmoid}$.

Αρχικά, το ConvStack εξάγει χαρακτηριστικά και ένα πρώτο πλήρως συνδεδεμένο στρώμα παράγει μια ενδιάμεση πρόβλεψη frame σχήματος $(B, T, 88)$. Στη συνέχεια, η πρόβλεψη αυτή συνενώνεται (concat) με τις πιθανότητες onset του Onset Detector, σχηματίζοντας ένα διάνυσμα 176 διαστάσεων ανά χρονικό πλαίσιο. Αυτή η σύνδεση επιτρέπει στον Frame Detector να γνωρίζει πότε ξεκίνησε μια νότα και να χρησιμοποιεί αυτή την πληροφορία για την πρόβλεψη

της διάρκειάς της. Το συνενωμένο διάνυσμα οδηγείται στο BiLSTM και έπειτα στο τελικό FullyCon + Sigmoid για την παραγωγή του frame piano roll.

Ο Velocity Detector εκτιμά το velocity κάθε νότας, δηλαδή πόσο δυνατά χτυπήθηκε το πλήκτρο. Η αρχιτεκτονική του είναι απλούστερη: ConvStack $\rightarrow$ FullyCon(88) $\rightarrow$ Sigmoid.

Χρησιμοποιεί το δικό του ConvStack και παράγει τιμές velocity στο $[0, 1]$ για κάθε πλήκτρο και χρονικό πλαίσιο. Κατά την εκπαίδευση, το σφάλμα του velocity υπολογίζεται μόνο στα onset frames (MSE masked loss), καθώς η πληροφορία του velocity αφορά αποκλειστικά τη στιγμή της έναρξης της νότας.

Η συνολική απώλεια του μοντέλου είναι άθροισμα τριών επιμέρους όρων:

- **Onset loss:** Binary Cross-Entropy (BCE) μεταξύ των προβλεπόμενων onset logits και των πραγματικών onset labels.
- **Frame loss:** Weighted BCE, όπου τα frames που αντιστοιχούν σε onset λαμβάνουν επιπλέον βάρος $c=5$ (onset_weight), σύμφωνα με το πρωτότυπο paper. Αυτό αποτρέπει το μοντέλο από το να αγνοεί τις εναρκτήριες στιγμές.
- **Velocity loss:** MSE μόνο στα onset frames, όπως αναφέρθηκε παραπάνω.

Ο βελτιστοποιητής που χρησιμοποιείται είναι ο Adam με αρχικό learning rate 6×10^{-4} , ενώ εφαρμόζεται gradient clipping με max norm 3.0 και scheduler StepLR που μειώνει το learning rate κατά 1/2 κάθε 20 εποχές.

Κατά το inference, εφαρμόζονται κατώφλια (thresholds) στις εξόδους onset και frame για την παραγωγή δυαδικών αποφάσεων. Ο κανόνας που ακολουθείται είναι αυτός του paper: μια νέα νότα ξεκινά μόνο αν είναι ενεργά ταυτόχρονα τόσο το onset όσο και το frame σε ένα χρονικό πλαίσιο. Εναλλακτικά, αν μια νότα ήταν ήδη ενεργή και εμφανιστεί νέο onset, η υπάρχουσα νότα κλείνει και ανοίγει νέα. Τελικά, οι νότες που παραμένουν ανοιχτές στο τέλος της ακολουθίας, κλείνουν στο τελευταίο frame.

5.2 Transformer (Encoder Only)

Το μοντέλο Transformer Encoder Only βασίζεται μόνο στο τμήμα του encoder της αρχιτεκτονικής Transformer. Αντί να χρησιμοποιηθεί η πλήρης αρχιτεκτονική encoder-decoder, το πρόβλημα του AMT μπορεί να διατυπωθεί ως πρόβλημα πρόβλεψης ανά χρονικό πλαίσιο (frame-wise prediction).

Η είσοδος του μοντέλου είναι η ακολουθία από χαρακτηριστικά που προκύπτουν από το mel-spectrogram, όπως περιγράφονται σε προηγούμενη ενότητα. Κάθε χρονικό πλαίσιο αυτής της ηχητικής αναπαράστασης θεωρείται ως ένα στοιχείο της ακολουθίας. Αρχικά, τα χαρακτηριστικά του κάθε frame προβάλλονται σε κατάλληλη διάσταση για τον Transformer. Συγκεκριμένα, σε αυτή την εργασία από 229 προβάλλονται σε 256 διαστάσεις. Στη συνέχεια, σε αυτά τα embeddings προστίθεται position encoding, ώστε το μοντέλο να διατη-

ρεί πληροφορία για τη χρονική θέση του κάθε frame μέσα στην ακολουθία, μιας και το self-attention από μόνο του δεν περιέχει πληροφορία για τη σειρά των στοιχείων της ακολουθίας.

Η ιδέα είναι ο Transformer encoder να κάνει self-attention, μέσω του οποίου κάθε χρονικό πλαίσιο συσχετίζεται με όλα τα υπόλοιπα της ακολουθίας. Αυτό είναι σημαντικό για τέτοιου είδους προβλήματα, επειδή στη μουσική περιέχονται χρονικές εξαρτήσεις μικρής και μεγάλης κλίμακας. Για παράδειγμα, η επανάληψη των μουσικών μοτίβων ή η συνέχεια μιας φράσης μπορεί να εξαρτάται από πληροφορία που βρίσκεται προηγουμένως ή σε διαφορετικά αποσπάσματα. Αμέσως μετά από το self-attention, η έξοδος κάθε encoder περνάει από ένα FeedForward network, το οποίο εφαρμόζεται σε κάθε χρονικό πλαίσιο και μετασχηματίζει τα χαρακτηριστικά που προέκυψαν από το self-attention. Συγκεκριμένα, σε αυτή την εργασία ο encoder αποτελείται από 4 encoder layers, με διάσταση 256, 8 attention heads, διάσταση feed forward 1024 και dropout 0.15.

Τέλος, η αναπαράσταση που έχει δημιουργηθεί για κάθε χρονικό πλαίσιο από τον Transformer encoder πηγαίνει σε δύο ανεξάρτητα fully connected heads. Το πρώτο head είναι για την πρόβλεψη του frame piano roll και το δεύτερο για την πρόβλεψη του onset piano roll.

5.3 CNN + Transformer (Encoder Only)

Σε αυτό το μοντέλο προστίθεται πριν από τον Transformer Encoder ένα συνελικτικό νευρωνικό δίκτυο, με σκοπό την εξαγωγή τοπικών χαρακτηριστικών από το mel-spectrogram. Τέτοια χαρακτηριστικά είναι, για παράδειγμα, το onset, το attack, οι αρμονικές κτλ., δηλαδή τα τοπικά ακουστικά χαρακτηριστικά. Στη συνέχεια, ο encoder του Transformer χρησιμοποιεί αυτά τα χαρακτηριστικά που εξάγονται, ώστε να μοντελοποιήσει τη χρονική εξέλιξη του κομματιού, μιας και μπορεί να μαθαίνει χρονικές εξαρτήσεις μεγάλου εύρους και να αξιοποιεί πληροφορία από μακρινά χρονικά πλαίσια.

Η αρχιτεκτονική του Transformer encoder παραμένει ίδια όπως προηγουμένως, ενώ η αρχιτεκτονική του συνελικτικού αποτελείται από δύο διαδοχικά συνελικτικά layers. Το πρώτο δέχεται ως είσοδο το mel-spectrogram και παράγει 32 feature maps, ενώ στο δεύτερο διπλασιάζονται και γίνονται 64. Και στα δύο επίπεδα χρησιμοποιείται πυρήνας 3×3 με padding 1×1 , ώστε να διατηρούνται οι διαστάσεις του χρόνου και της συχνότητας. Μετά από κάθε συνέλιξη εφαρμόζεται batch normalization και η συνάρτηση ενεργοποίησης GELU. Στο τέλος εφαρμόζεται dropout με rate 0.15 για τη μείωση του overfitting.

Από την έξοδο για κάθε χρονικό πλαίσιο, τα 64 feature maps συνδυάζονται με τις 229 ζώνες συχνότητων, οπότε δημιουργείται ένα διάνυσμα διαστάσεων 64×229 . Το διάνυσμα προβάλλεται μέσω ενός fully connected layer στη διά-

σταση εισόδου του Transformer, που σε αυτό το συγκεκριμένο μοντέλο είναι 256. Έτσι, η πληροφορία που εξήχθη από το συνελκτικό μετατρέπεται σε ακολουθία embeddings, που μπορεί να χειριστεί ο Transformer encoder.

5.4 Transformer (Encoder-Decoder)

Σε αντίθεση με το μοντέλο Transformer Encoder Only, το οποίο διατυπώνει το πρόβλημα του AMT ως πρόβλεψη ανά χρονικό πλαίσιο (frame-wise), το μοντέλο Encoder-Decoder αντιμετωπίζει το AMT ως πρόβλημα ακολουθίας-προς-ακολουθία (sequence-to-sequence). Το τμήμα του κωδικοποιητή λειτουργεί όπως ακριβώς περιγράφηκε στην προηγούμενη ενότητα - δηλαδή self-attention πάνω στα χρονικά πλαίσια του mel-spectrogram με προσθήκη positional encoding - και επομένως δεν επαναλαμβάνεται εδώ. Η ουσιαστική διαφορά είναι η προσθήκη ενός αποκωδικοποιητή (decoder), ο οποίος παράγει αυτοπαλινδρομικά (autoregressively) μια ακολουθία διακριτών συμβόλων (tokens) που αντιστοιχούν σε συμβάντα MIDI.

Αντί για δύο piano-roll heads (frame και onset) που χρησιμοποιεί το μοντέλο Encoder Only, η έξοδος αναπαρίσταται εδώ ως μια ακολουθία διακριτών tokens. Το λεξιλόγιο αποτελείται από 311 σύμβολα: συμβάντα έναρξης νότας (NOTE_ON) και λήξης νότας (NOTE_OFF) για καθένα από τα 88 πλήκτρα του πιάνου, κβαντισμένες τιμές έντασης (velocity), κβαντισμένες χρονικές μετατοπίσεις (time-shift) με βήμα 10 ms, καθώς και τα ειδικά σύμβολα PAD, BOS και EOS. Έτσι, κάθε μουσικό γεγονός εκφράζεται ως μια ακολουθία της μορφής “χρονική μετατόπιση → ένταση → έναρξη/λήξη νότας”, επιτρέποντας τη συμπαγή και ακριβή αναπαράσταση πολυφωνικής μουσικής.

Ο αποκωδικοποιητής συνδυάζει δύο μηχανισμούς προσοχής. Ο πρώτος είναι masked self-attention πάνω στα ήδη παραχθέντα tokens, ώστε η πρόβλεψη κάθε συμβόλου να εξαρτάται μόνο από τα προηγούμενα. Ο δεύτερος είναι cross-attention προς την αναπαράσταση (μνήμη) που παράγει ο κωδικοποιητής, μέσω της οποίας κάθε παραγόμενο token συσχετίζεται με τα σχετικά χρονικά πλαίσια του ηχητικού σήματος - με αυτόν τον τρόπο η παραγωγή των νοτών καθοδηγείται απευθείας από τον ήχο. Η διαδικασία παραγωγής είναι αυτοπαλινδρομική: ξεκινά από το σύμβολο BOS και συνεχίζεται έως ότου παραχθεί το σύμβολο EOS.

Επειδή οι ακολουθίες των tokens μπορούν να γίνουν αρκετά μεγάλες, για τον περιορισμό του υπολογιστικού κόστους του μηχανισμού προσοχής χρησιμοποιείται αραιή (sparse) προσοχή. Αντί για πλήρη (πυκνή) προσοχή σε όλα τα ζεύγη θέσεων, ο μηχανισμός συνδυάζει έναν τοπικό κλάδο, που εστιάζει σε γειτονικά πλαίσια, με έναν ολικό (global) κλάδο για τη σύλληψη εξαρτήσεων μεγαλύτερης κλίμακας. Σε αυτό το χαρακτηριστικό οφείλεται και ο χαρακτηρισμός του μοντέλου ως Sparse Transformer.

Ως είσοδος χρησιμοποιείται mel-spectrogram με 229 ζώνες συχνότητας, σε ρυθμό δειγματοληψίας 16 kHz και hop length 512 δειγμάτων, ενώ τα κομμάτια τεμαχίζονται σε αποσπάσματα διάρκειας 20 δευτερολέπτων. Όπως αναφέρθηκε στην ενότητα του συνόλου δεδομένων, χρησιμοποιείται το ίδιο υποσύνολο του MAESTRO (διαγωνισμοί 2011, 2013 και 2014) για όλα τα μοντέλα, ώστε η σύγκριση των αποτελεσμάτων να είναι δίκαιη.

Συγκεκριμένα, σε αυτή την εργασία η αρχιτεκτονική του μοντέλου είναι η ακόλουθη. Το μοντέλο διαθέτει συνολικά 8.973.879 εκπαιδεύσιμες παραμέτρους, ενώ η έξοδος του κωδικοποιητή υφίσταται συγκέντρωση (pooling) σε 128 χρονικά πλαίσια πριν προσπελαστεί από τον αποκωδικοποιητή μέσω του cross-attention.

6 Εκπαίδευση

6.1 CNN + LSTM

Τα δεδομένα εισόδου έχουν $n_mels=229$ και $seq_len=327$ χρονικά πλαίσια (20 δευτερόλεπτα ήχου με hop size 512 και sample rate 16000 Hz). Κάθε segment φορτώνεται εξ' ολοκλήρου στη μνήμη RAM (preloaded tensors) ώστε να ελαχιστοποιείται ο χρόνος I/O κατά την εκπαίδευση. Η διάσπαση των δεδομένων γίνεται τυχαία με αναλογία 80%/10%/10% (train/val/test). Το μοντέλο εκπαιδεύεται για 100 εποχές και αποθηκεύονται checkpoints κάθε 5 εποχές. Η εκπαίδευση του μοντέλου CNN + LSTM αποδείχθηκε ιδιαίτερα απαιτητική σε υπολογιστικούς πόρους και χρόνο. Κάθε εποχή διαρκούσε σημαντικό χρονικό διάστημα λόγω του μεγέθους του συνόλου δεδομένων (7.761 segments εκπαίδευσης) σε συνδυασμό με την υπολογιστική πολυπλοκότητα του BiLSTM. Η εκπαίδευση ολοκληρώθηκε έως την εποχή 30, όπου παρατηρήθηκε σταθεροποίηση τόσο της απώλειας όσο και των μετρικών αξιολόγησης. Συγκεκριμένα, από την εποχή 21 έως την 31 το Val Frame F1 κυμαίνεται μεταξύ 0.627 και 0.642 χωρίς σαφή ανοδική τάση.

6.2 Transformer (Encoder Only)

Για την εκπαίδευση αυτού του μοντέλου, ο διαχωρισμός των δεδομένων πραγματοποιήθηκε σε επίπεδο μουσικού κομματιού, ώστε αποσπάσματα από το ίδιο κομμάτι να μην εμφανίζονται ταυτόχρονα σε διαφορετικά σύνολα. Συγκεκριμένα, χρησιμοποιήθηκε το 70% για την εκπαίδευση, 15% για την επικύρωση και 15% για την τελική αξιολόγηση.

Μιας και το πρόβλημα είναι ένα multi-label classification πρόβλημα, χρησιμοποιήθηκε ως loss function το Binary Cross Entropy with Logits. Το loss function

εφαρμόστηκε ξεχωριστά στην έξοδο του frame head και στην έξοδο του onset head. Το συνολικό loss υπολογίστηκε ως συνδυασμός αυτών των δύο. Συγκεκριμένα, ορίστηκε ως:

$$L = L_{\text{frame}} + 3 \cdot L_{\text{onset}}$$

Δόθηκε μεγαλύτερο βάρος στην πρόβλεψη των onsets, καθώς εμφανίζονται πιο αραιά σε σχέση με τα frames και είναι πιο δύσκολη η πρόβλεψή τους με ακρίβεια. Επιπλέον, χρησιμοποιήθηκαν βάρη και στη συνάρτηση κόστους. Για το frame piano-roll ορίστηκε ίσο με 2, ενώ για το onset piano-roll ορίστηκε ίσο με 4.

Ως optimizer χρησιμοποιήθηκε ο AdamW, με learning rate $2e-4$ και weight decay $1e-4$. Το μοντέλο εκπαιδεύτηκε για 200 εποχές με batch size 16. Κατά την εκπαίδευση εφαρμόστηκε gradient clipping με μέγιστη νόρμα ίση με 1, ώστε να περιορίζονται πολύ μεγάλες τιμές των gradients και να γίνεται η διαδικασία εκπαίδευσης πιο σταθερή. Το μοντέλο της εποχής με το υψηλότερο F1-score στο σετ επικύρωσης κρατήθηκε για την τελική αξιολόγηση. Μετά από κάθε εποχή υπολογιζόταν η απόδοση του μοντέλου στο training set και στο validation set. Οι έξοδοι του μοντέλου μετατρέπονται σε πιθανότητες μέσω της συνάρτησης sigmoid και στη συνέχεια εφαρμόζονται thresholds για την παραγωγή δυαδικών piano-rolls.

Πριν την τελική αξιολόγηση, στο καλύτερο μοντέλο γίνεται ένα threshold tuning, με το σετ επικύρωσης, ώστε να βρεθούν τα κατάλληλα thresholds, και επιλέχθηκαν οι τιμές που έδιναν το καλύτερο F1-score.

6.3 CNN + Transformer (Encoder Only)

Η διαδικασία εκπαίδευσης αυτού του μοντέλου είναι παρόμοια με του Transformer Encoder Only, καθώς είναι επέκτασή του. Προστίθεται ένα συνελκτικό νευρωνικό δίκτυο, το οποίο λειτουργεί ως feature extractor πριν από τον Transformer Encoder. Το loss function και οι υπερπαραμέτροι παραμένουν τα ίδια, όπως και στο τέλος γίνεται το threshold tuning πριν από την τελική αξιολόγηση.

6.4 Transformer (Encoder-Decoder)

Το μοντέλο Transformer Encoder-Decoder εκπαιδεύτηκε με συνάρτηση σφάλματος cross-entropy και label smoothing 0.1, με μέγεθος batch ίσο με 8, για 150 εποχές. Χρησιμοποιήθηκε πρόγραμμα ρυθμού μάθησης με σταδιακή προθέρμανση (warmup) και στη συνέχεια μείωση τύπου inverse square root, με μέγιστο ρυθμό μάθησης της τάξης του 1×10^{-4} . Κατά την εκπαίδευση εφαρμό-

στηκε teacher forcing, ενώ διατηρήθηκε το μοντέλο με το χαμηλότερο σφάλμα επικύρωσης.

Κατά τη διάρκεια της εκπαίδευσης, το σφάλμα εκπαίδευσης μειώθηκε από περίπου 5,15 σε 2,86 και το σφάλμα επικύρωσης ακολούθησε στενά (περίπου 2,89), χωρίς ένδειξη υπερπροσαρμογής. Επιπλέον, παρακολουθήθηκε ένας διαγνωστικός δείκτης (έλεγχος cross-attention με ανακατεμένο ήχο), ο οποίος επιβεβαίωσε ότι ο αποκωδικοποιητής αξιοποιεί πραγματικά το ηχητικό σήμα και δεν εκφυλίζεται σε καθαρό γλωσσικό μοντέλο των tokens. Ο δείκτης αυτός αυξανόταν σταθερά κατά τη διάρκεια της εκπαίδευσης, υποδεικνύοντας υγιή σύγκλιση.

7 Μετρικές

Για την αξιολόγηση των μοντέλων χρησιμοποιήθηκε η βιβλιοθήκη `mir_eval`, η οποία παρέχει κατάλληλες μετρικές για προβλήματα μουσικής μεταγραφής. Αυτή η βιβλιοθήκη επιτρέπει με ευκολία να παραχθούν οι μετρικές που θα χρησιμοποιηθούν. Ο τρόπος που τις υπολογίζει είναι με βάση τις νότες και όχι σε επίπεδο χρονικών frames. Οπότε, πρώτα πρέπει να υπολογιστούν οι νότες με βάση τις προβλέψεις.

Η κάθε νότα έχει μια αρχή, ένα τέλος και τη συχνότητά της (τονικό ύψος). Για να υπολογιστεί το τονικό ύψος χρησιμοποιείται ο παρακάτω τύπος:

$$f = 440 \times 2^{\frac{m-69}{12}}$$

όπου m είναι ο MIDI αριθμός της νότας και f η αντίστοιχη συχνότητα σε Hz. Για τον υπολογισμό της αρχής και του τέλους της νότας, στην περίπτωση της frame-wise υλοποίησης υπάρχουν δύο προσεγγίσεις.

Στην πρώτη, χρησιμοποιείται μόνο το frame piano-roll. Για κάθε νότα εξετάζεται η ακολουθία των χρονικών frames και εντοπίζονται τα συνεχόμενα διαστήματα στα οποία η νότα προβλέπεται ως ενεργή. Η αρχή αυτού του διαστήματος θεωρείται ως onset, ενώ το τέλος τους ως offset. Με αυτόν τον τρόπο οι νότες δημιουργούνται αποκλειστικά από το frame piano-roll.

Στη δεύτερη, χρησιμοποιείται ο συνδυασμός του frame piano-roll και του onset piano-roll. Μια νότα θεωρείται ότι ξεκινά μόνο όταν υπάρχει πρόβλεψη onset στο αντίστοιχο χρονικό frame και ταυτόχρονα η νότα προβλέπεται ως ενεργή στο frame piano-roll. Από αυτό το σημείο και μετά υπολογίζεται το διάστημα όπως πριν. Αυτή η προσέγγιση μπορεί να δώσει πιο ακριβή χρονική τοποθέτηση της αρχής των νοτών.

Για το μοντέλο Transformer Encoder-Decoder, η έξοδος δεν είναι κάποιο piano-roll αλλά είναι ακολουθία από διακριτά μουσικά γεγονότα. Τα παραγόμενα tokens, όπως note-on, note-off και time-shift, μετατρέπονται απευθείας

σε νότες. Τα time-shift tokens χρησιμοποιούνται για την ενημέρωση του τρέχοντος χρόνου, τα note-on tokens δηλώνουν την έναρξη μιας νότας και τα note-off tokens δηλώνουν τη λήξη της.

Αφού δημιουργηθούν οι προβλεπόμενες νότες, τότε συγκρίνονται με τις πραγματικές που προέρχονται από τα MIDI αρχεία. Η σύγκριση γίνεται με βάση το πότε ξεκινάει η κάθε νότα, το τονικό ύψος και, όπου χρησιμοποιείται, το τέλος της νότας. Για να θεωρηθεί μια προβλεπόμενη νότα σωστή, πρέπει να υπάρχει μια αντιστοιχία σε μια πραγματική νότα με παρόμοιο τονικό ύψος και χρονική στιγμή έναρξης ή και λήξης, αν χρησιμοποιηθεί, μέσα σε μια συγκεκριμένη ανοχή. Η ανοχή που χρησιμοποιήθηκε για το onset αντιστοιχεί σε ένα χρονικό frame και, για το offset όπου χρησιμοποιείται, αντιστοιχεί έως 6.

Οι μετρικές που χρησιμοποιήθηκαν είναι η precision, η recall και το F1-score. Η precision δείχνει τι ποσοστό των νοτών που προέβλεψε το μοντέλο είναι σωστές. Η recall δείχνει τι ποσοστό των πραγματικών νοτών κατάφερε να εντοπίσει το μοντέλο. Το F1-score είναι ο συνδυασμός του precision και της recall και χρησιμοποιείται ως συνολική μετρική απόδοσης.

8 Αποτελέσματα

Για την τελική αξιολόγηση, οι μετρικές που υπολογίζονται είναι για 3 κατηγορίες για το πρόβλημα frame-wise:

- **Note:** υπολογίζεται μόνο με τη χρήση του frame piano roll.
- **Note w/ onset:** υπολογίζεται με τη χρήση του frame piano roll και του onset piano roll για την έναρξη της νότας.
- **Note w/ onset + offset:** υπολογίζεται με τη χρήση του frame piano roll και του onset piano roll για την έναρξη της νότας, όμως, για να θεωρηθεί μια νότα σωστή, πρέπει να τελειώνει μέσα στην ανοχή που της έχει δοθεί.

Για την προσέγγιση autoregressive:

- **Note:** υπολογίζεται απο την δημιουργια της νότας από τα tokens που παρήχθησαν, η ανοχή που έχει για την αρχή της νότας είναι στα 50ms.
- **Note w/ offset:** υπολογίζεται απο την δημιουργια της νότας από τα tokens που παρήχθησαν, αλλά για να θεωρηθεί μια νότα σωστή, πρέπει να τελειώνει μέσα στην ανοχή που της έχει δοθεί.

8.1 CNN + LSTM

Πίνακας 1: Αποτελέσματα για το μοντέλο CNN + LSTM

Μετρική	Precision	Recall	F1
Note	0.7006	0.5769	0.6246
Note w/ onset	0.8821	0.5957	0.6986
Note w/ onset + offset	0.4255	0.2941	0.3426

8.2 Transformer (Encoder Only)

Πίνακας 2: Αποτελέσματα για το μοντέλο Transformer Encoder Only

Μετρική	Precision	Recall	F1
Note	0.5602	0.5483	0.5344
Note w/ onset	0.5754	0.1519	0.2343
Note w/ onset + offset	0.1743	0.0462	0.0713

8.3 CNN + Transformer (Encoder Only)

Πίνακας 3: Αποτελέσματα για το μοντέλο CNN + Transformer Encoder Only

Μετρική	Precision	Recall	F1
Note	0.6937	0.7040	0.6854
Note w/ onset	0.9156	0.6652	0.6652
Note w/ onset + offset	0.4476	0.3320	0.3774

8.4 Transformer (Encoder-Decoder)

Πίνακας 4: Αποτελέσματα για το μοντέλο Transformer Encoder-Decoder

Μετρική	Precision	Recall	F1
Note	0.0745	0.0536	0.0602
Note w/ offset	0.0354	0.0233	0.0272

9 Σχολιασμός των αποτελεσμάτων

Από τα αποτελέσματα παρατηρείται ότι το μοντέλο CNN + Transformer Encoder Only έχει την καλύτερη συνολική απόδοση ανάμεσα στα μοντέλα που εξετάστηκαν. Στην αξιολόγηση που χρησιμοποιείται μόνο το frame piano-roll, πετυχαίνει F1-score 0.6854, ενώ στη μετρική που συνδυάζει το frame piano-roll με το onset piano-roll, αλλά πρέπει και να τελειώνει η νότα σε συγκεκριμένο χρονικό πλαίσιο (Note w/ onset + offset), που είναι αρκετά πιο αυστηρή, πετυχαίνει F1-score 0.3774. Η επίδοση αυτή δείχνει ότι ο συνδυασμός ενός συνελικτικού front-end με τον Transformer Encoder είναι ιδιαίτερα αποτελεσματικός για το συγκεκριμένο πρόβλημα. Το συνελικτικό βοηθάει στην εξαγωγή τοπικών χαρακτηριστικών, ενώ ο Transformer Encoder αξιοποιεί πληροφορία από μεγαλύτερα χρονικά διαστήματα.

Το μοντέλο CNN + LSTM παρουσιάζει παρόμοια απόδοση με το μοντέλο CNN + Transformer Encoder Only. Στη μετρική Note πετυχαίνει F1-score 0.6246 και 0.6986 στη μετρική Note w/ onset. Αυτό δείχνει ότι για αυτό το σύνολο δεδομένων που χρησιμοποιήθηκε, το LSTM μετά από ένα CNN μπορεί να μοντελοποιήσει αποτελεσματικά τη χρονική εξέλιξη των χαρακτηριστικών. Βέβαια, όταν η αξιολόγηση γίνεται πιο αυστηρή και λαμβάνεται υπόψη και το πότε τελειώνει μια νότα, τότε η απόδοσή του μένει χαμηλά, με F1-score 0.3426.

Το μοντέλο Transformer Encoder Only παρουσιάζει τη χαμηλότερη απόδοση από όλα τα frame-wise μοντέλα. Παρόλο που στο Note πετυχαίνει F1-score 0.5344, όταν χρησιμοποιείται το onset piano roll, οι αποδόσεις πέφτουν δραματικά. Στη μετρική Note w/ onset το F1-score είναι 0.2343, ενώ στη μετρική Note w/ onset + offset πέφτει στο 0.0713. Αυτό δείχνει ότι η χρήση ενός CNN ήταν σημαντική στην αναγνώριση των χαρακτηριστικών για το onset piano-roll.

Το μοντέλο Transformer Encoder-Decoder έχει τη χαμηλότερη απόδοση από όλα τα μοντέλα. Στη μετρική Note πέτυχε F1-score 0.0602, ενώ στη μετρική Note w/ offset το F1-score ήταν 0.0272. Παρόλο που τέτοιου είδους αρχιτεκτονικές επιτρέπουν τη μεταγραφή να γίνει ως πρόβλημα παραγωγής ακολουθίας MIDI-like events, σε αυτή την υλοποίηση δεν κατάφερε να δώσει καλά αποτελέσματα. Αυτό πιθανόν να οφείλεται στη δυσκολία της autoregressive παραγωγής μεγάλων ακολουθιών από note-on, note-off και time-shift tokens. Ένα λάθος token κατά την αποκωδικοποίηση μπορεί να επηρεάσει ολόκληρη τη συνέχεια της παραγόμενης ακολουθίας.

Συνολικά, τα αποτελέσματα δείχνουν ότι οι frame-wise προσεγγίσεις αποδίδουν καλύτερα στο συγκεκριμένο σύνολο δεδομένων, ιδιαίτερα όταν προστίθεται και ένα CNN.

10 Περιορισμοί

10.1 CNN + LSTM

Τα αποτελέσματα αποκαλύπτουν μια χαρακτηριστική ανισορροπία μεταξύ precision και recall. Η υψηλή precision στη μετρική Note (0.88) υποδηλώνει ότι όταν το μοντέλο προβλέπει μια νότα, αυτή είναι σχεδόν πάντα σωστή. Αντίθετα, το recall (0.60) αποκαλύπτει ότι το μοντέλο αστοχεί σε περίπου 40% των πραγματικών νοτών, τείνοντας να είναι συντηρητικό. Αυτή η συμπεριφορά είναι αναμενόμενη για μοντέλο που εκπαιδεύτηκε μόνο 30 εποχές. Επιπλέον, υπάρχει απότομη πτώση από Note F1=0.70 σε Note w/ offset F1=0.34, που αποκαλύπτει ότι το μοντέλο ενώ εντοπίζει σωστά τις εναρκτήριες στιγμές των νοτών, αδυνατεί να προβλέψει με ακρίβεια τη διάρκειά τους. Τέλος, η μικρή περαιτέρω πτώση από Note w/ offset (0.34) σε Note w/ offset & velocity (0.31) υποδηλώνει ότι η εκτίμηση του velocity είναι σχετικά καλή, αφού το velocity loss (0.0038) ήταν άλλωστε από τις πρώτες εποχές χαμηλό.

10.2 Transformer (Encoder Only)

Ο βασικός περιορισμός αυτού του μοντέλου είναι ότι δεν περιλαμβάνει κάποιο συνελικτικό κομμάτι πριν από τον Transformer. Επομένως, αυτό δυσκολεύει την εξαγωγή χαρακτηριστικών όπως τα attack, οι αρμονικές κτλ., τα οποία εμφανίζονται ως τοπικά μοτίβα. Αυτό φαίνεται και από τα αποτελέσματα, μιας και δεν καταφέρνει να βρει τα onset.

10.3 CNN + Transformer (Encoder Only)

Παρόλο που το μοντέλο CNN + Transformer Encoder Only παρουσίασε την καλύτερη συνολική απόδοση ανάμεσα στα μοντέλα που εξετάστηκαν, εξακολουθεί να έχει κάποιους περιορισμούς. Η έξοδος είναι σε μορφή frame και onset piano-rolls, που σημαίνει ότι οι νότες δεν προβλέπονται απευθείας ως μουσικά γεγονότα με αρχή και τέλος. Αυτό δημιουργεί έμμεσα προβλήματα, μιας και ένα μικρό λάθος σε ένα από αυτά μπορεί να τεμαχίσει τις νότες στη μέση ή να τους δώσει πολύ μικρότερη διάρκεια από την πραγματική. Επίσης, η χρήση Transformer Encoder αυξάνει το υπολογιστικό κόστος σε σχέση με απλούστερες αρχιτεκτονικές, όπως η χρήση του LSTM. Παρόλο που αυτό είναι διαχειρίσιμο για αποσπάσματα μικρής διάρκειας, μπορεί να γίνει πιο σημαντικό για αποσπάσματα με μεγαλύτερη διάρκεια ή εάν υπάρχει μεγαλύτερη χρονική ανάλυση.

10.4 Transformer (Encoder-Decoder)

Ένα σημαντικό εύρημα αφορά την αναπαράσταση των tokens. Αρχικά, η κβάντιση του χρόνου εισήγαγε προοδευτική απόκλιση (drift) στους χρόνους έναρξης των νοτών κατά την ανακατασκευή, με αποτέλεσμα το θεωρητικά εφικτό F1@50ms να περιορίζεται στο 0.12 - ανεξάρτητα από την ποιότητα του μοντέλου. Μετά τη διόρθωση της κωδικοποίησης, ώστε κωδικοποιητής και αποκωδικοποιητής να μοιράζονται το ίδιο ρολόι, το ανώτατο όριο ανέβηκε στο 0,998. Το εύρημα αυτό αναδεικνύει τη σημασία του ελέγχου του ανώτατου ορίου του tokenizer πριν από κάθε συμπέρασμα για την απόδοση του μοντέλου.

Παρά τη διόρθωση αυτή, η τελική απόδοση μεταγραφής παραμένει χαμηλή. Η ανάλυση έδειξε ότι το μοντέλο αξιοποιεί το ηχητικό σήμα λιγότερο από ό,τι θα ήταν επιθυμητό για ένα σύστημα πλήρως καθοδηγούμενο από τον ήχο. Εντοπίστηκαν τρεις κύριες αιτίες: (α) ο κωδικοποιητής επεξεργάζεται 512 από τα 626 διαθέσιμα χρονικά πλαίσια mel, δηλαδή 16,4 από τα 20 δευτερόλεπτα, αφήνοντας περίπου το 18% κάθε αποσπάσματος χωρίς αντίστοιχο ήχο, (β) ο τοπικός κλάδος της αραιής cross-attention υποθέτει ότι ο δείκτης του token είναι ανάλογος του χρόνου, υπόθεση που δεν ισχύει στην πολυφωνική μουσική, καθώς μια συγχορδία παράγει πολλά tokens στην ίδια χρονική στιγμή, και (γ) υπάρχει απόκλιση μεταξύ της ακρίβειας με teacher forcing και της ελεύθερης αυτοπαλινδρομικής παραγωγής (exposure bias).

Οι παρατηρήσεις αυτές ορίζουν σαφείς κατευθύνσεις για μελλοντική βελτίωση: αύξηση του παραθύρου εισόδου ώστε να καλύπτεται ολόκληρο το απόσπασμα, αντικατάσταση του υβριδικού μηχανισμού προσοχής με πλήρη cross-attention για επιβεβαίωση του ορίου, και τεχνικές μείωσης του exposure bias.

11 Συμπεράσματα

Σε αυτή την εργασία εξετάστηκε το πρόβλημα της αυτόματης μουσικής μεταγραφής με τη χρήση διαφορετικών προσεγγίσεων και μοντέλων. Συγκεκριμένα, υλοποιήθηκαν και συγκρίθηκαν τα μοντέλα CNN + LSTM, Transformer Encoder Only, CNN + Transformer Encoder Only και Transformer Encoder-Decoder.

Από τα αποτελέσματα προκύπτει ότι οι frame-wise προσεγγίσεις απέδωσαν καλύτερα από την encoder-decoder προσέγγιση, ειδικά όταν σε αυτές προστίθεται και ένα συνελικτικό δίκτυο για την εξαγωγή τοπικών χαρακτηριστικών από το mel-spectrogram. Το καλύτερο μοντέλο ήταν το CNN + Transformer Encoder Only, ενώ παρόμοια αποτελέσματα αλλά με λιγότερες υπολογιστικές απαιτήσεις είχε το CNN + LSTM. Το Transformer Encoder Only είχε χαμηλά

αποτελέσματα όταν γίνεται η χρήση του onset piano roll, μιας και δεν μπόρεσε να εξάγει τα χαρακτηριστικά που χρειαζόταν, όπως στα άλλα μοντέλα, όπου αυτό έγινε με τη χρήση CNN. Το Transformer Encoder-Decoder, ενώ αποτελεί πιο άμεση προσέγγιση για την παραγωγή MIDI-like γεγονότων, δεν κατάφερε να αποδώσει ικανοποιητικά σε αυτή την υλοποίηση.

Συνολικά, αυτή η εργασία δείχνει ότι η χρήση ενός CNN ως front-end είναι σημαντική για την αυτόματη μουσική μεταγραφή, ειδικά για την ανίχνευση των onsets. Βέβαια, η ακριβής εκτίμηση των offsets και της διάρκειας των νοτών παραμένει δύσκολη και αποτελεί μια κατεύθυνση που μπορεί να ακολουθηθεί για μελλοντική βελτίωση.